ANÁLISIS DESCRIPTIVO DE VENTAS Y ENTREGAS EN EL MARKETPLACE OLIST

VIGILADO MINEDUCACIÓN

PROYECTO INTEGRADOR: ANÁLISIS DESCRIPTIVO DE LAS VENTAS POR CATEGORÍA DE PRODUCTO, REGIÓN Y TIEMPO DE ENTREGA EN EL MARKETPLACE OLIST (2016-2018)

Etapa 1: ideación, diseño y documentación de la necesidad (EA2)

PRESENTADO POR:
CARLOS ESTEBAN TRUJILLO PAZ

ASIGNATURA:
PROYECTO INTEGRADO III - ANALÍTICA DE DATOS
GRUPO:
PREICA2602B020038

DOCENTE:
ANDRÉS FELIPE CALLEJAS

INSTITUCIÓN UNIVERSITARIA DIGITAL DE ANTIOQUIA
MEDELLÍN, COLOMBIA

OCTUBRE 2026

Tabla de contenido

1. Introducción 5
2. Planteamiento de la necesidad 5
2.1 Escenario y beneficiario 5
2.2 Necesidad de información 6
2.3 Pregunta de análisis 6
3. Justificación 7
4. Objetivos 8
4.1 Objetivo general 8
4.2 Objetivos específicos 8
5. Marco teórico inicial 8
5.1 Comercio electrónico y marketplace 8
5.2 Indicadores comerciales descriptivos 9
5.3 Desempeño logístico de la entrega 9
5.4 Analítica descriptiva 9
5.5 Unidad de análisis y datos ordenados 10
5.6 Calidad de datos: valores faltantes 10
6. Metodología de la etapa 1 10
6.1 Selección y ficha del dataset 10
6.2 Tablas utilizadas y construcción del DataFrame 11
6.3 Unidad de análisis 12
6.4 Diccionario inicial de variables 12
6.5 Alcance y limitaciones 13
6.6 Diseño inicial del análisis 14
7. Reconocimiento del dataset 15
7.1 Contenido del DataFrame 15
7.2 Valores nulos 16
7.3 Cómo las variables permiten abordar la necesidad 16
Referencias 18
Anexo A. Repositorio del proyecto 18

Índice de tablas

Tabla 1**.** *Ficha del dataset* 11

Tabla 2**.** *Tablas del dataset utilizadas*..... 11
Tabla 3**.** *Diccionario inicial de variables relevantes*..... 12
Tabla 4**.** *Relación entre la pregunta, las variables y los resultados esperados* 15
Tabla 5**.** *Valores nulos en variables relevantes*..... 16

1. Introducción

El comercio electrónico genera un registro detallado de cada venta: qué se vendió, a qué precio, a quién, desde dónde y cuánto tardó en llegar. Ese registro permite describir cómo se comporta un negocio a partir de datos y no solo de percepciones. Este documento presenta la primera etapa del proyecto integrador del curso Proyecto Integrado III - Analítica de Datos: la ideación, el diseño y la documentación de una necesidad de analítica descriptiva.

Para el proyecto se seleccionó el dataset **Brazilian E-Commerce Public Dataset by Olist**, publicado en Hugging Face con el identificador bulutttt/olist-raw-data. Contiene datos reales y anonimizados de cerca de 100.000 órdenes realizadas entre 2016 y 2018 en Olist Store, un servicio que conecta pequeños comercios brasileños con grandes marketplaces. El dataset describe cada orden desde varias dimensiones: estado, precio y flete de los productos, fechas de compra y entrega, categoría del producto y ubicación del cliente y del vendedor.

El propósito del análisis es caracterizar y comparar cómo se distribuyen las ventas entre categorías de producto y regiones de Brasil, y cómo varía el tiempo de entrega entre esos grupos, de modo que un equipo comercial pueda identificar dónde se concentra la actividad del negocio y dónde se presentan demoras. En esta etapa se plantea la necesidad, la pregunta de análisis, los objetivos y el diseño inicial, y se realiza un reconocimiento del dataset mediante un notebook de Jupyter que obtiene los datos desde Hugging Face y genera automáticamente un resumen en un archivo .txt.

2. Planteamiento de la necesidad

2.1 Escenario y beneficiario

Escenario hipotético. El equipo comercial y de operaciones de un marketplace como Olist Store debe decidir en qué categorías de producto y en qué regiones concentrar sus esfuerzos comerciales (campañas, incorporación de vendedores, negociación con transportadoras). Para ello necesita una visión consolidada de las ventas registradas. El escenario es hipotético: el análisis no fue

solicitado por Olist y se construye con fines académicos a partir de sus datos públicos.

Beneficiario. El equipo comercial y de operaciones del marketplace. De forma secundaria, los vendedores que publican en la plataforma, que podrían usar los resultados para comparar el desempeño de su categoría y región.

2.2 Necesidad de información

El equipo requiere conocer **qué categorías de producto y qué estados de Brasil concentran las unidades vendidas y los ingresos por venta de productos, y cómo se comporta el tiempo de entrega en cada uno de esos grupos**. Esta información serviría para priorizar categorías y regiones en las decisiones comerciales y para identificar grupos donde las entregas tardan más o llegan después de la fecha estimada.

Se trata de una **necesidad propuesta**, no de un problema observado y comprobado: no se parte de la afirmación de que existan demoras o concentraciones anómalas, sino de la falta de una descripción consolidada que permita conocer la situación. Si existen diferencias entre grupos, el análisis las describirá; no pretende explicar sus causas.

2.3 Pregunta de análisis

¿Cómo se distribuyen las unidades vendidas y los ingresos por venta de productos entre las categorías de producto y los estados del cliente en las órdenes de Olist registradas entre septiembre de 2016 y septiembre de 2018, y cómo varía el tiempo de entrega entre esos grupos?

La pregunta es descriptiva y se responde con variables disponibles en el dataset:

a) **Unidades vendidas:** conteo de ítems de orden (cada fila es un producto vendido).

b) **Ingresos por venta de productos:** suma de la variable price.

c) **Categoría de producto:** product_category_name_english.

d) **Estado del cliente:** customer_state.

e) **Tiempo de entrega:** diferencia entre order_delivered_customer_date y order_purchase_timestamp, comparada con order_estimated_delivery_date.

3. Justificación

En un marketplace, conocer dónde se concentran las ventas y cómo se cumplen las entregas es información básica para decidir. Sin una descripción consolidada, las decisiones sobre qué categorías promover o en qué regiones reforzar la logística se toman con información parcial. Un análisis descriptivo ofrece una línea base verificable: rankings de categorías y estados, participación de cada grupo en las ventas y medidas del tiempo de entrega.

El dataset de Olist permite abordar esta necesidad por las siguientes razones:

a) Registra cada producto vendido con su precio, su categoría y la orden a la que pertenece, lo que permite calcular unidades e ingresos por categoría.

b) Incluye la ubicación del cliente (estado y ciudad), lo que permite comparar regiones.

c) Incluye las fechas de compra, entrega real y entrega estimada, lo que permite calcular tiempos de entrega y cumplimiento de la fecha estimada.

d) Son datos reales y anonimizados, con un volumen suficiente (112.650 ítems vendidos) para describir grupos con confianza, y pueden procesarse con los recursos de un computador personal.

e) Es público y su licencia (CC BY-NC-SA 4.0) permite el uso académico no comercial con atribución.

4. Objetivos

4.1 Objetivo general

Describir la distribución de las unidades vendidas y de los ingresos por venta de productos según la categoría de producto y el estado del cliente, y el comportamiento del tiempo de entrega en esos grupos, a partir de las órdenes de Olist registradas entre 2016 y 2018, para apoyar la priorización comercial y logística de un marketplace.

4.2 Objetivos específicos

1. Caracterizar el dataset en cuanto a volumen de órdenes, ítems, clientes, vendedores y productos, periodo cubierto y presencia de valores nulos.
2. Cuantificar las unidades vendidas, los ingresos y la participación porcentual de cada categoría de producto, e identificar las diez categorías con mayores ingresos.
3. Comparar las unidades vendidas, los ingresos y el ingreso promedio por ítem entre los estados del cliente.
4. Calcular, para las órdenes entregadas, el tiempo de entrega en días (mediana y promedio) y el porcentaje de entregas posteriores a la fecha estimada, por categoría y por estado.
5. Describir la evolución mensual de las unidades vendidas y los ingresos durante el periodo.

El objetivo específico 1 se desarrolla en esta etapa (sección 7). Los objetivos 2 a 5 se desarrollarán en las siguientes etapas del proyecto integrador.

5. Marco teórico inicial

5.1 Comercio electrónico y marketplace

Una transacción de comercio electrónico es la venta o compra de bienes o servicios realizada a través de redes informáticas mediante métodos diseñados específicamente para recibir o colocar pedidos (OECD, 2011). Un marketplace es

una plataforma en la que múltiples vendedores ofrecen sus productos a los compradores a través de un mismo canal. En el caso de Olist, pequeños comercios venden en grandes marketplaces brasileños mediante un único contrato y despachan los productos a los clientes con los socios logísticos de Olist (Olist & Sionek, 2018). Por esto, una misma orden puede contener varios productos y cada producto puede ser despachado por un vendedor distinto.

5.2 Indicadores comerciales descriptivos

Para describir las ventas se usarán indicadores básicos: **unidades vendidas** (cantidad de productos vendidos), **ingresos por venta de productos** (suma de los precios de los productos vendidos, sin incluir el flete), **participación porcentual** (proporción de las unidades o ingresos de un grupo sobre el total) e **ingreso promedio por ítem** (ingresos divididos entre unidades). Estos indicadores permiten ordenar y comparar categorías y regiones.

5.3 Desempeño logístico de la entrega

El **tiempo de entrega** es el número de días entre la compra y la recepción del producto por el cliente. El **cumplimiento de la fecha estimada** indica si la entrega real ocurrió antes o después de la fecha informada al cliente en el momento de la compra. Olist señala el desempeño de las entregas como uno de los aspectos que el dataset permite estudiar (Olist & Sionek, 2018).

5.4 Analítica descriptiva

La analítica descriptiva usa datos históricos para responder qué ocurrió, mediante agregaciones, medidas de tendencia central y de dispersión, tablas y gráficos (Evans, 2020). A diferencia de la analítica predictiva o prescriptiva, no busca pronosticar ni recomendar acciones, sino caracterizar y comparar lo observado. Por eso es adecuada para una primera aproximación a una necesidad de información como la planteada.

5.5 Unidad de análisis y datos ordenados

En un conjunto de datos ordenado, cada variable forma una columna, cada observación forma una fila y cada tipo de unidad de observación forma una tabla (Wickham, 2014). Definir la unidad de análisis (qué representa cada fila) es necesario para interpretar correctamente los conteos y las sumas. En este proyecto, los datos de Olist están repartidos en varias tablas relacionadas por llaves (identificadores de orden, producto, cliente y vendedor), que se integran en un solo DataFrame cuya unidad de análisis es el ítem de orden.

5.6 Calidad de datos: valores faltantes

Un valor faltante o nulo indica que no hay dato registrado para una variable en una observación. En pandas se representan como NaN o None y se identifican con métodos como isna (pandas development team, s.f.). Antes de analizar es necesario cuantificarlos y entender su origen, porque pueden reflejar situaciones del negocio (por ejemplo, una orden cancelada no tiene fecha de entrega) y no solo errores de registro.

6. Metodología de la etapa 1

6.1 Selección y ficha del dataset

Se exploraron datasets tabulares de Hugging Face relacionados con ventas y comercio. Se descartó un dataset sintético de comercio electrónico porque su acceso estaba restringido (requería autenticación) y sus datos no eran reales. Se seleccionó la copia pública del dataset de Olist porque: (a) se descarga sin autenticación, (b) contiene datos reales de un negocio comercial, (c) incluye variables numéricas, categóricas y de fecha que permiten comparar cantidades, grupos y periodos, y (d) su tamaño (alrededor de 45 MB en las tablas utilizadas) se procesa sin dificultad en un computador personal.

La copia en Hugging Face no incluye una ficha (dataset card) propia. Por eso, la procedencia, la descripción y la licencia se tomaron de la publicación original en Kaggle (Olist & Sionek, 2018) y se comprobó que la copia es consistente con ella:

contiene los mismos archivos y 99.441 órdenes, en línea con las cerca de 100.000 órdenes que declara la fuente original.

Tabla 1**.** *Ficha del dataset*

Campo	Descripción
Nombre	Brazilian E-Commerce Public Dataset by Olist
Identificador en Hugging Face	bulutttt/olist-raw-data
Enlace directo	https://huggingface.co/datasets/bulutttt/olist-raw-data
Fuente original	Olist, publicado en Kaggle: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce
Revisión utilizada	5acf1f37d7197d4979e714721a1ec13a7c3da728 (repositorio actualizado el 24/08/2026)
Split o configuración	Split train (único disponible). Cada tabla se carga por su archivo .csv (parámetro data_files).
Fecha de consulta	25 de octubre de 2026
Tipo de datos	Reales y anonimizados. No son sintéticos.
Periodo	Compras entre el 4 de septiembre de 2016 y el 3 de septiembre de 2018
Tamaño	9 archivos .csv, cerca de 126 MB en total; 6 archivos utilizados, cerca de 45 MB
Licencia	CC BY-NC-SA 4.0 (atribución, no comercial, compartir igual), según la fuente original
Muestra	No se usa muestra: se cargan todos los registros de los archivos utilizados

Fuente: elaboración propia con base en Olist y Sionek (2018) y bulutttt (2026).

6.2 Tablas utilizadas y construcción del DataFrame

El dataset está dividido en tablas relacionadas. Para la necesidad se usan seis de ellas; no se usan la tabla de geolocalización (coordenadas por código postal) ni la de reseñas, porque no son necesarias para la pregunta. Tampoco se usa la tabla de pagos: los ingresos se miden con el precio de los productos, que se registra por ítem y se puede atribuir a una categoría, mientras que los pagos se registran por orden.

Tabla 2**.** *Tablas del dataset utilizadas*

Archivo	Filas	Contenido	Llave de unión
olist_order_items_dataset.csv	112.650	Productos vendidos en cada orden, con precio y flete	Base del DataFrame
olist_orders_dataset.csv	99.441	Estado de la orden y fechas de compra, aprobación y entrega	order_id
olist_products_dataset.csv	32.951	Categoría y atributos físicos del producto	product_id
product_category_name_translation.csv	71	Traducción de las categorías del portugués al inglés	product_category_name

Archivo	Filas	Contenido	Llave de unión
olist_customers_dataset.csv	99.441	Identificador único y ubicación del cliente	customer_id
olist_sellers_dataset.csv	3.095	Ubicación del vendedor	seller_id

Fuente: elaboración propia.

Las tablas se obtienen desde Hugging Face con la clase HFDatasetLoader del proyecto y se integran mediante uniones de tipo left join a partir de la tabla de ítems. El notebook comprueba que el DataFrame resultante tiene exactamente las mismas 112.650 filas que la tabla de ítems, es decir, que las uniones no duplicaron ni eliminaron registros. El DataFrame final tiene 30 columnas.

6.3 Unidad de análisis

La unidad de análisis es el **ítem de orden**: cada fila del DataFrame representa un producto vendido dentro de una orden, con su precio, su flete, la categoría del producto, la ubicación del cliente y del vendedor, y las fechas de la orden. Una orden con tres productos aparece en tres filas. Por eso el DataFrame tiene 112.650 filas y 98.666 órdenes distintas. Esta unidad permite sumar unidades e ingresos por categoría de forma directa.

6.4 Diccionario inicial de variables

La Tabla 3 describe las variables relevantes para la necesidad. Los significados se tomaron de la documentación de la fuente original. La moneda de los precios no está declarada explícitamente en la ficha; se infiere que son reales brasileños (BRL) por tratarse de un marketplace brasileño y se deja como pendiente de verificar.

Tabla 3**.** *Diccionario inicial de variables relevantes*

Variable	Significado	Tipo de dato	Unidad
order_id	Identificador de la orden	Texto (object)	No aplica
order_item_id	Número consecutivo del producto dentro de la orden	Entero (int64)	No aplica
product_id	Identificador del producto	Texto (object)	No aplica
seller_id	Identificador del vendedor que despacha el producto	Texto (object)	No aplica
customer_unique_id	Identificador único del cliente (un cliente puede tener varias órdenes)	Texto (object)	No aplica

Variable	Significado	Tipo de dato	Unidad
price	Precio del producto vendido	Decimal (float64)	BRL (por verificar)
freight_value	Valor del flete del producto; si la orden tiene varios productos, el flete se reparte entre ellos	Decimal (float64)	BRL (por verificar)
order_status	Estado de la orden: delivered, shipped, canceled, invoiced, processing, unavailable, approved	Texto categórico (object)	No aplica
order_purchase_timestamp	Fecha y hora de la compra	Texto con fecha (object); se convertirá a fecha	Fecha y hora
order_delivered_customer_date	Fecha y hora real de entrega al cliente	Texto con fecha (object)	Fecha y hora
order_estimated_delivery_date	Fecha estimada de entrega informada al cliente al comprar	Texto con fecha (object)	Fecha
product_category_name	Categoría del producto, en portugués	Texto categórico (object)	No aplica
product_category_name_english	Categoría del producto traducida al inglés	Texto categórico (object)	No aplica
customer_state	Estado de Brasil donde se ubica el cliente (sigla de dos letras)	Texto categórico (object)	No aplica
customer_city	Ciudad del cliente	Texto categórico (object)	No aplica
seller_state	Estado de Brasil donde se ubica el vendedor	Texto categórico (object)	No aplica
product_weight_g	Peso del producto	Decimal (float64)	Gramos

Fuente: elaboración propia con base en Olist y Sionek (2018) y en los tipos de dato obtenidos en el notebook.

6.5 Alcance y limitaciones

Alcance.

a) Unidad de análisis: ítem de orden.

b) Población cubierta: los ítems de las órdenes de Olist Store incluidas en el dataset público (112.650 ítems de 98.666 órdenes). No representa todas las ventas de Olist ni todo el comercio electrónico de Brasil.

c) Periodo: compras entre septiembre de 2016 y septiembre de 2018.

d) Variables: precio, categoría, estado del cliente, estado de la orden y fechas de compra, entrega real y entrega estimada (Tabla 3).

e) Tipo de análisis: descriptivo, orientado a caracterizar y comparar los datos observados.

Limitaciones: lo que los datos no permiten afirmar.

a) No permiten establecer causas: si una categoría o un estado tiene más demoras, el análisis lo describirá pero no podrá explicar por qué.

b) No hay costos ni márgenes, por lo que no se puede hablar de rentabilidad; los ingresos corresponden al precio de venta de los productos, sin flete ni descuentos.

c) El tiempo de entrega solo puede calcularse para órdenes entregadas; 2.454 ítems (2,18 %) no tienen fecha de entrega.

d) 1.627 ítems (1,44 %) no tienen categoría en inglés; se agruparán como sin categoría.

e) Los datos llegan hasta 2018 y están anonimizados: describen el periodo observado, no la situación actual.

f) La moneda de los precios está pendiente de verificar en la fuente original.

6.6 Diseño inicial del análisis

El análisis se desarrollará en los siguientes pasos:

1. **Obtención:** cargar las seis tablas desde Hugging Face con HFDatasetLoader, fijando la revisión del repositorio para que los datos sean siempre los mismos (realizado en esta etapa).
2. **Integración y reconocimiento:** unir las tablas en un DataFrame de ítems, describir su contenido y generar el resumen .txt (realizado en esta etapa).
3. **Preparación:** convertir las fechas de texto a fecha, agrupar las categorías nulas como sin categoría, calcular el tiempo de entrega en días, marcar las entregas posteriores a la fecha estimada y derivar el mes de compra.
4. **Descripción:** calcular unidades, ingresos, participación e ingreso promedio por categoría, por estado y por mes; calcular mediana y promedio del tiempo de entrega y porcentaje de entregas tardías por grupo.

5. **Comunicación:** presentar los resultados en tablas y gráficos de barras y de líneas.

Tabla 4**.** *Relación entre la pregunta, las variables y los resultados esperados*

Componente de la pregunta	Variables	Resultado esperado
Unidades por categoría y por estado	Conteo de filas, product_category_name_english, customer_state	Ranking de categorías y estados por unidades vendidas
Ingresos por categoría y por estado	price, product_category_name_english, customer_state	Ranking por ingresos, participación % e ingreso promedio por ítem
Periodo	order_purchase_timestamp	Serie mensual de unidades e ingresos
Tiempo de entrega por grupo	order_purchase_timestamp, order_delivered_customer_date, order_status	Mediana y promedio de días de entrega por categoría y por estado
Cumplimiento de la fecha estimada	order_delivered_customer_date, order_estimated_delivery_date	Porcentaje de entregas posteriores a la fecha estimada por grupo

Fuente: elaboración propia.

7. Reconocimiento del dataset

El reconocimiento se realizó en el notebook AE2/notebooks/AE2_reconocimiento_olist.ipynb, que obtiene los datos desde Hugging Face, construye el DataFrame, muestra registros, dimensiones, columnas, tipos de datos y valores nulos, y genera automáticamente el resumen AE2/resultados/resumen_dataframe.txt. Las cifras de esta sección provienen de esa ejecución.

7.1 Contenido del DataFrame

El DataFrame tiene **112.650 filas y 30 columnas**, sin filas duplicadas. Cada fila es un producto vendido. En conjunto, los datos corresponden a 98.666 órdenes, 95.420 clientes, 3.095 vendedores y 32.951 productos, con compras entre el 4 de septiembre de 2016 y el 3 de septiembre de 2018. Las columnas combinan identificadores (orden, producto, cliente y vendedor), valores numéricos (precio, flete y atributos físicos del producto), categorías (estado de la orden, categoría del producto, ciudad y estado) y fechas, que llegan como texto y se convertirán a fecha en la siguiente etapa.

El precio de los productos tiene una mediana de 74,99 y un promedio de 120,65, con valores entre 0,85 y 6.735,00; el promedio es mayor que la mediana porque algunos productos de precio alto elevan la media. El flete tiene una mediana de 16,26. El 97,8 % de los ítems (110.197) pertenece a órdenes entregadas; el resto corresponde a órdenes enviadas, canceladas, facturadas, en proceso, no disponibles o aprobadas.

Las categorías con más ítems vendidos son bed_bath_table (cama, mesa y baño; 11.115), health_beauty (salud y belleza; 9.670), sports_leisure (deportes y ocio; 8.641), furniture_decor (muebles y decoración; 8.334) y computers_accessories (computadores y accesorios; 7.827). Por región, São Paulo (SP) concentra el 42,1 % de los ítems comprados (47.449), seguido de Río de Janeiro (14.579) y Minas Gerais (13.129). Del lado de la oferta, el 71,3 % de los ítems fue despachado por vendedores de São Paulo.

7.2 Valores nulos

El DataFrame tiene 11.774 valores nulos en total, concentrados en pocas variables. La Tabla 5 resume los relevantes para la necesidad; las demás variables relevantes no tienen nulos.

Tabla 5**.** *Valores nulos en variables relevantes*

Variable	Nulos	%	Interpretación
order_delivered_customer_date	2.454	2,18	Órdenes aún no entregadas o canceladas
product_category_name_english	1.627	1,44	Productos sin categoría en el origen (1.603 ítems) o con categoría sin traducción al inglés (24 ítems)
product_weight_g	18	0,02	Productos sin atributos físicos registrados
price, customer_state, order_status, order_purchase_timestamp	0	0,00	Completas

Fuente: elaboración propia con base en el resumen generado por el notebook.

7.3 Cómo las variables permiten abordar la necesidad

El reconocimiento confirma que el dataset contiene las variables que exige la pregunta y que están suficientemente completas. El precio y la categoría están disponibles para casi todos los ítems, por lo que es posible calcular unidades e ingresos por categoría. El estado del cliente no tiene nulos, lo que permite comparar

las 27 unidades federativas de Brasil. Las fechas de compra, entrega real y entrega estimada permiten calcular el tiempo de entrega y el cumplimiento de la fecha estimada para el 97,8 % de los ítems que pertenecen a órdenes entregadas. La fuerte concentración en São Paulo, observada en este reconocimiento, indica que en la siguiente etapa conviene presentar tanto valores absolutos como porcentajes, para que la comparación entre estados sea justa.

Referencias

bulutttt. (2026). *olist-raw-data* [Conjunto de datos]. Hugging Face. https://huggingface.co/datasets/bulutttt/olist-raw-data

Evans, J. R. (2020). *Business analytics: Methods, models, and decisions* (3.ª ed.). Pearson.

Hugging Face. (s.f.). *Datasets documentation*. https://huggingface.co/docs/datasets

OECD. (2011). *OECD guide to measuring the information society 2011*. OECD Publishing. https://doi.org/10.1787/9789264113541-en

Olist, & Sionek, A. (2018). *Brazilian E-Commerce Public Dataset by Olist* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

pandas development team. (s.f.). *pandas documentation*. https://pandas.pydata.org/docs/

Wickham, H. (2014). Tidy data. *Journal of Statistical Software, 59*(10), 1-23. https://doi.org/10.18637/jss.v059.i10

Anexo A. Repositorio del proyecto

El código, el notebook ejecutado, el resumen generado y este documento están publicados en el repositorio de GitHub del curso:

https://github.com/EstebanAdso/PI3_2026Q4-Proyecto-Integrado-III-Analitica-de-Datos

a) AE2/notebooks/AE2_reconocimiento_olist.ipynb: notebook de obtención y reconocimiento del dataset.

b) AE2/resultados/resumen_dataframe.txt: resumen del DataFrame generado automáticamente.

c) AE2/documento/: este documento.

d) src/clases_po/: clases HFDatasetLoader y DatasetSummarizer.